

Previsão de Qualidade de Vinho com *Aprendizado de Máquina*

Relatório executivo de criação, otimização e análise de desempenho do Modelo Preditivo de Classificação de Vinhos Premium

Equipe de Pesquisa:

André Carlos Soares de Souza

Anne Pimentel Alexandre da Silva

Ewerton Pereira Reis

Contexto: Tech Challenge (Fase 2) - FIAP Pós-Tech Data Analytics

Pós-tech FIAP | Machine Learning | Data Analytics

Previsão de Qualidade de Vinho com Aprendizado de Máquina

1. Introdução

Este projeto tem como objetivo o desenvolvimento de um modelo de Machine Learning capaz de prever a nota de qualidade do vinho. Historicamente, a classificação de excelência de uma safra tem dependido exclusivamente da análise sensorial de especialistas, um processo subjetivo que necessita de profissionais altamente qualificados, o que além de custoso pode levar tempo até que um vinho seja classificado.

A base de dados utilizada foi o Wine Quality Dataset, disponível publicamente no Kaggle, que contém cerca de 11 mil registros de diferentes amostras de vinho, como acidez, teor alcoólico, densidade, pH, sulfatos e etc. Cada amostra também possui uma nota de qualidade atribuída por especialistas, que será utilizada como variável alvo para o desenvolvimento de modelos de classificação.

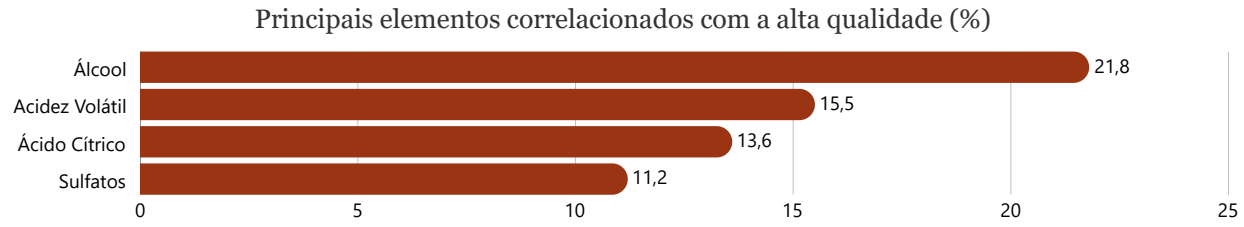
Ao integrar as análises independentes desenvolvidas por nossa equipe de dados, construímos uma visão abrangente sobre o que define um "vinho premium". Para isso, o modelo avalia as propriedades físico-químicas da bebida, traduzindo essas características em padrões preditivos de alta precisão. Essa abordagem orientada a dados reduz a dependência de avaliações manuais, padronizando a classificação de forma objetiva e acelerando o tempo de resposta. Como resultado, entregamos uma ferramenta escalável que otimiza custos operacionais e apoia diretamente a tomada de decisão estratégica.



2. Como Identificar um Vinho de Qualidade Superior?

A análise exploratória de dados revelou que a percepção humana de qualidade não é um evento aleatório, mas sim a resposta como elementos fundamentais interagem para direcionar a nota de qualidade final de um lote. Aroma e sabor, acidez, corpo, fazem parte do conjunto que, segundo especialistas, definem a qualidade de um vinho.

No banco de dados utilizado neste projeto, foi feita uma análise de correlação que corrobora com o conhecimento apresentado por enólogos profissionais. No gráfico abaixo, apresentamos os elementos com maior correlação com a alta qualidade de um vinho.



Fonte: Tabela de Correlação - Notebook 01_eda

Teor Alcoólico: Vinhos premium, na base de dados, consistentemente apresentam graduação alcoólica superior (geralmente acima de 11.5%). Isso reflete principalmente ao “corpo”, que é a sensação de peso e textura do vinho na boca.



Sulfatos: Atuam como conservantes e antioxidantes. O modelo detectou que níveis ligeiramente mais altos estão correlacionados a notas elevadas.

Acidez Volátil: Em baixas concentrações, pode dar um toque complexidade ao vinho. Porém, quando está excessiva, torna-se um defeito que estraga o aroma e o sabor.

Ácido Cítrico: Pode parecer contraditório, mas a acidez é o que dá vivacidade e frescor ao vinho.

3. Abordagem de Modelagem Preditiva e Ganhos de Otimização

Para automatizar a classificação de qualidade, a equipe testou inicialmente três algoritmos, Regressão Logística, Random Forest e KNN. O algoritmo que demonstrou a melhor relação entre capacidade de generalização e estabilidade foi o Random Forest, que foi o escolhido para este caso. Posteriormente, foi testado o XGBoost, mas não demonstrou um ganho significativo para justificar a mudança do modelo escolhido.

No entanto, a implementação do Random Forest, embora promissora, ainda apresentava dificuldades em distinguir os vinhos premium das categorias logo abaixo deles. Foi necessária uma etapa rigorosa de otimização de hiperparâmetros (ajuste fino das engrenagens matemáticas do modelo) para extrair o máximo valor preditivo da nossa base de dados.

3.1. Impacto da Otimização: Padrão vs. Otimizado

A tabela abaixo sintetiza a evolução do nosso principal algoritmo, comparando a versão inicial de desenvolvimento (Padrão) com o modelo final calibrado pela equipe (Otimizado). Os ganhos de precisão traduzem-se diretamente em menos falsos positivos e na maior garantia de qualidade do nosso modelo.

Métrica de Avaliação	Random Forest (Padrão)	Random Forest (Otimizado)	Impacto Direto no Negócio
Taxa de Captura de Vinhos Premium (Recall)	31,4%	**69,0%**	Salto expressivo na capacidade de identificar e resgatar os melhores vinhos do estoque, reduzindo a perda de oportunidades comerciais.
Precisão para Vinhos Premium	76,4%	**52,0%**	Recuo calculado da precisão em prol da abrangência, mantendo um volume controlado de alarmes falsos.
Equilíbrio Operacional (F1-Score)	44,1%	**59,0%**	A versão otimizada com limiar ajustado está mais harmoniosa e eficiente para lidar com o desbalanceamento da base.

No modelo padrão (com o corte rígido de 50%), o algoritmo era extremamente cauteloso: quando dizia que um vinho era premium, ele acertava 76,4% das vezes. No entanto, por conta desse conservadorismo, ele deixava escapar quase 70% das garrafas de alta qualidade, gerando um Recall de 31,4%. Ao flexibilizar o limiar para 45,57%, aceitou-se uma precisão menor (52%) em troca de um ganho considerável na captação.



4. Aplicações Práticas e Próximos Passos

A entrega técnica deste modelo abre portas para diversas transformações operacionais, passando da análise reativa para uma inteligência proativa de produção.

4.1 Triagem Automática e Alocação de Recursos

Com o modelo Random Forest Otimizado em produção, os resultados laboratoriais de cada novo lote podem ser processados instantaneamente. Vinhos classificados com potencial de nota de qualidade “Alta” podem ser separados para tratamentos de envelhecimento em carvalho, por exemplo, enquanto amostras projetadas para notas de qualidade “Comum” podem ser redirecionadas para blends de volume ou intervenções corretivas emergenciais.

4.2. Apoio Estratégico à Precificação

O nível de qualidade previsto fornece uma base quantitativa sólida para definir o posicionamento de mercado do produto. A equipe comercial não precisa mais esperar semanas pelas avaliações unânimes dos degustadores para iniciar o planejamento de go-to-market de uma safra. O score gerado pelo algoritmo atua como uma bússola confiável de precificação inicial.

4.3. Retroalimentação do Banco de Dados

A qualidade do vinho e as preferências do mercado não são grandezas exatas e imutáveis. É recomendado estabelecer um fluxo contínuo de informação com o time responsável pela produção. O sistema precisa de um ciclo de aprendizado contínuo para garantir que o modelo aprenda os novos padrões químicos e não fique obsoleto.

4.4. Inserção de Novos Elementos no *Dataset*

Identificamos a falta de mais indicadores sobre a qualidade percebida ao paladar humano, já que o modelo atual avalia apenas a composição química. Para uma versão 2.0, a empresa poderia coletar detalhes sobre a origem como o tipo de uva, o clima da safra e o tempo em barril, ou quaisquer fatores não computados neste *dataset* que possam afetar a qualidade do vinho e impactar na sua nota final, deixando o modelo ainda acertivo.

5. Análise de Limitações do Modelo Atual

O treinamento e aprendizado do modelo ocorreram em uma base de dados com um grande desbalanceamento, onde apenas cerca de 14% das garrafas representavam vinhos premium. Embora esse viés estatístico tenha sido contornado com o ajuste do limiar de decisão, a baixa exposição a exemplos de alta qualidade restringe a capacidade do algoritmo de identificar padrões mais complexos de excelência.

Outra limitação do modelo otimizado reside na dificuldade matemática de equilibrar perfeitamente a precisão e a abrangência da busca, estabelecendo um teto de desempenho evidenciado pelo F1-Score de 0,59 no conjunto de teste. Mesmo com o ajuste ideal da régua de decisão para 45,57%, o sistema estabilizou com uma precisão de 52%, o que significa que a operação ainda precisará lidar com alarmes falsos, visto que no teste classificou 20 garrafas comuns equivocadamente como de alta qualidade. Após a otimização, o modelo agora abrange quase 70% de toda a reserva de melhores vinhos sem disparar falsos alarmes o tempo todo, o que foi uma melhora positiva, porém no teste a ferramenta ainda deixou passar 10 garrafas premium que não foram detectadas.

Uma possível causa para esse limite de confiabilidade baixo é, além do desbalanceamento já citado, a natureza restrita dos próprios dados, uma vez que o algoritmo tenta prever a nota final avaliando única e exclusivamente a composição química do produto. Como apontado anteriormente, o modelo sofre com a falta de indicadores sobre a qualidade percebida ao paladar humano. Pelo fato de o sistema desconhecer detalhes fundamentais da origem e produção, o algoritmo não possui os dados necessários para explicar completamente por que químicas semelhantes podem resultar em qualidades tão diferentes.

6. Conclusão

Com o modelo finalizado, foi possível automatizar a triagem dos melhores vinhos, mesmo lidando com as limitações metodológicas inerentes à dependência exclusiva de propriedades físico-químicas e um dataset original desbalanceado. Apesar dos desafios impostos pela complexidade das classes, o modelo otimizado demonstra estar no caminho certo e exibe grande aplicabilidade prática para o negócio. Ao alcançar uma acurácia global de 87% e um equilíbrio operacional promisor após o ajuste do limiar de decisão, a ferramenta comprova seu potencial para automatizar e otimizar a triagem de vinhos, pavimentando um caminho sólido para evoluções futuras com a integração de dados sensoriais e contextuais.



7. Referências Bibliográficas

Scikit-learn Documentation <https://scikit--learn-org.translate.goog/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html?_x_tr_sl=en&_x_tr_tl=pt&_x_tr_hl=pt&_x_tr_pto=tc>

IBM <https://www.ibm.com/br-pt/think/topics/random-forest>

ANSIC Brasil <https://ansicbrasil.com.br/blogs/blog/aprenda-sobre-as-principais-caracteristicas-de-um-bom-vinho>

g1 Globo Paraná RPC <https://g1.globo.com/pr/parana/especial-publicitario/porto-a-porto/guia-do-vinho-e-da-gastronomia/noticia/2026/10/13/os-5-atributos-que-voce-deve-procurar-no-vinho-para-saber-se-e-bom.ghtml>

Porto a Porto Vinho & Gastronomia <https://www.portoaporto.com.br/blog/vinho/como-saber-se-um-vinho-e-bom-de-verdade/>

WineFun <https://winefun.com.br/entenda-seus-vinhos-equilibrio-e-maturacao-fenolica-e-tecnologica/>

